

Modelo de Artigo para o SBrT 2026

Nome1 Sobrenome1 e Nome2 Sobrenome2

Resumo— Este documento apresenta um exemplo de utilização do estilo $\LaTeX$ sbirt.cls para preparar um artigo para submissão ao SBrT 2026. O resumo deve conter no máximo 100 palavras.

Palavras-Chave— Modelo de artigo, $\LaTeX$, SBrT 2026.

Abstract— This document is an example of how to use the $\LaTeX$ style sbirt.cls to prepare a paper for submission to SBrT 2026. The abstract must have at most 100 words.

For papers written in English, please drop both sections above (Resumo and Palavras-Chave).

Keywords— Paper template, $\LaTeX$, SBrT 2026.

I. INTRODUÇÃO

A autenticação de sinais em canais de desvanecimento Rayleigh representa um desafio fundamental em sistemas de comunicação segura. O presente trabalho implementa uma abordagem baseada em redes neurais profundas para resolver o problema de teste de hipótese binária em contextos de autenticação física de camada. O procedimento metodológico compreende três etapas fundamentais: a geração controlada de dados de treinamento, o treinamento de um classificador neural, e a validação comparativa contra métodos clássicos de detecção. Este documento descreve cada uma dessas etapas em detalhe técnico.

II. O PROBLEMA DO TESTE DE HIPÓTESE

O problema é formulado como o teste de hipótese binária descrito abaixo.

- H_0 (Hipótese Nula): Transmissão fraudulenta - o atacante envia mensagem sem TAG
 - H_1 (Hipótese Alternativa): Transmissão autêntica (contém TAG e ela é legítima) - o usuário legítimo envia uma TAG secreta derivada de uma sequência caótica.
- O receptor recebe:

$$y = h \cdot m(x) + n$$

em que: - y = sinal recebido - h = coeficiente do canal (Rayleigh, desconhecido) - $m(x)$ = mensagem modulada + TAG - n = ruído aditivo gaussiano branco (AWGN) com variância apropriada ao nível de sinal para ruído especificado.

A. Arquitetura do Sinal e Componentes Físicos

A mensagem é modulada em esquema de modulação por chaveamento de deslocamento de fase binária (BPSK) com potência normalizada de $\rho_s = \sqrt{0.985}$. A sequência TAG é gerada através de iteração de um mapa caótico do tipo tenda,

Nome1 Sobrenome1, Departamento1, Universidade1, Cidade1-UF1, e-mail: xxxxx@yyyyy.zzzzz.br; Nome2 Sobrenome2, Departamento2, Universidade2, Cidade2-UF2, e-mail: xxxxx@yyyyy.zzzzz.br. Este trabalho foi parcialmente financiado por XXXXXXXX (XX/XXXXX-X).

definido pela recorrência $x_{n+1} = 1 - 2|x_n - 0.5| - 10^{-6}$, onde o termo de perturbação 10^{-6} garante comportamento caótico não convergente. A potência da sequência TAG é mantida em $\rho_t = 0.124$, com normalização final que garante $E[tag^2] \approx 1/3$. O coeficiente do canal Rayleigh é amostrado de acordo com a distribuição $h \sim \text{Rayleigh}(1/\sqrt{2})$, refletindo condições típicas de propagação em ambientes urbanos com múltiplos percursos.

III. REDE NEURAL

A rede neural implementada para investigar esse problema é uma DNN (Deep Neural Network) otimizada para testes de hipótese binária no contexto de autenticação em camada física em canais AWGN com desvanecimento Rayleigh. A arquitetura foi projetada para:

- Aprender uma fronteira de decisão não-linear que supera a simples estratégia de limiar fixo
- Combinar múltiplas estatísticas (correlador, estimativa de canal, SNR, energia) para aumentar robustez
- Alcançar taxa de falso negativo (FNR) 10, comparável ao baseline de Monte Carlo
- Ser computacionalmente eficiente (100k parâmetros, inferência < 10ms)

A. Geração de Dados de Treinamento

1) *Estratégia de Amostragem Estratificada*: A estratégia de geração de dados adota uma abordagem de amostragem estratificada em seis níveis de razão sinal-ruído para cobrir o intervalo [0,30] dB. Este intervalo foi selecionado para corresponder diretamente aos cenários de teste em trabalhos de referência na literatura ****inserir referencia aqui****. A faixa total de SNR é dividida em seis regiões de aproximadamente cinco decibéis cada. Para as regiões correspondentes a SNR baixo (faixa de zero a dez decibéis), onde a decisão entre as hipóteses H_0 e H_1 é mais desafiadora, aumenta-se a amostragem por um fator multiplicativo de 1,5. Nas regiões de SNR mais elevado (acima de dez decibéis), mantém-se o fator de amostragem unitário. Esta estratégia de sobreamostragem nas regiões críticas garante que o modelo aprenda a diferenciar as hipóteses precisamente onde o problema é mais difícil, evitando *overfitting* aos regimes de SNR elevado onde a classificação é trivial.

2) *Esquema de Aumento de Dados*: Além da amostragem por partes, implementa-se um esquema sistemático de aumento de dados sintéticos para a faixa crítica de SNR entre zero e oito decibéis. O procedimento começa selecionando amostras de alta qualidade com SNR superior a quinze decibéis, que apresentam hipóteses com correlação bem distinta e características estatísticas confiáveis. Para cada amostra selecionada, calcula-se o fator de degradação de ruído como *rudo_escala* =

$10^{(SNR_{original}-SNR_{alvo})/20}$. O correlator é então redimensionado conforme $\tau_{novo} = \tau_{original}/rudo_escala$, simulando a degradação esperada de correlação sob adição de ruído. A energia do sinal é incrementada proporcionalmente como $E_{novo} = E_{original} \times (1 + fator_rudo)$, refletindo que a potência total (sinal mais ruído) aumenta em canais com SNR reduzido. Através deste procedimento, amostras de alta qualidade com propriedades bem conhecidas são sinteticamente degradadas, preservando seus rótulos verdadeiros enquanto criam dados realistas para o regime crítico de baixo SNR.

3) *2.5 Composição Final do Conjunto de Dados:* A abordagem combinada de amostragem estratificada e aumento de dados resulta em um conjunto de treinamento compreendendo aproximadamente quatrocentos e cinquenta mil amostras. Deste total, trezentas mil amostras são geradas nativamente através de simulação Monte Carlo direta, enquanto setenta e cinco mil amostras adicionais são produzidas através do procedimento de aumento sintético aplicado à faixa de zero a oito decibéis. O conjunto é perfeitamente balanceado em classes, com cinquenta por cento das amostras rotuladas como autênticas (H_1) e cinquenta por cento como fraudulentas (H_0). O vetor de características extraído de cada amostra compreende quatro componentes: o correlator casado clássico (estatística de teste ótima sob ruído gaussiano), uma estimativa do coeficiente do canal (calculada como a magnitude média do sinal recebido), a razão sinal-ruído local estimada em escala logarítmica (decibéis), e a energia total do sinal recebido. Cada característica é individualmente normalizada através de transformação de padronização (StandardScaler), resultando em média zero e desvio padrão unitário, prática essencial para garantir convergência estável durante o treinamento neural.

4) *2.6 Particionamento Treino-Validação-Teste:* O conjunto de quatrocentos e cinquenta mil amostras é particionado mantendo estratificação por classe e SNR. Oitenta por cento do conjunto, equivalente a trezentos e sessenta mil amostras, é designado para treinamento do modelo. Dez por cento (quarenta e cinco mil amostras) é reservado para validação durante o treinamento, com o propósito de monitorar overfitting e executar parada antecipada. Os dez por cento finais (quarenta e cinco mil amostras) constituem o conjunto de teste, utilizado exclusivamente para avaliação de desempenho em dados completamente invistos. Esta partição segue o protocolo padrão de aprendizado de máquina e garante que todas as conclusões sobre desempenho generalizável do modelo sejam baseadas em dados que nunca influenciaram parâmetros treináveis.

B. 3. Treinamento da Rede Neural Profunda

1) *3.1 Arquitetura de Rede:* A rede neural profunda implementada segue a arquitetura proposta por Braca et al. em seu trabalho de 2022 sobre teste de hipótese estatística baseado em aprendizado de máquina. A topologia compreende uma camada de entrada com quatro neurônios correspondendo às quatro características engenheiradas, seguida por três camadas ocultas densamente conectadas com reduções dimensionais sucessivas, e uma camada de saída com um único neurônio empregando função de ativação sigmoide.

A primeira camada oculta transforma o espaço de características de quatro dimensões para duzentos e cinquenta e

seis dimensões através de uma matriz de pesos treinável. Especificamente, cada uma das duzentas e cinquenta e seis unidades calcula uma combinação linear de todas as quatro características de entrada, adicionando um viés aprendível. Esta expansão dimensional inicial permite que a rede desenvolva representações intermediárias ricas que capturam interações não-lineares entre as características originais. Após a transformação linear, aplica-se a função de ativação ReLU (unidade linear retificada), definida como $ReLU(x) = \max(0, x)$. Esta função introduz não-linearidade essencial, permitindo que a rede aprenda fronteiras de decisão complexas e não-convexas. Seguindo a ativação, une-se uma camada de normalização de lote (BatchNormalization) que padroniza as ativações de cada unidade durante treinamento. A normalização é executada sobre minilotes de duzentos e cinquenta e seis amostras, garantindo que as distribuições de entrada para camadas subsequentes permaneçam estáveis e centradas em zero. Após a normalização de lote, aplica-se regularização através de abandono (Dropout) com probabilidade de desativação de trinta por cento, desligando aleatoriamente trinta por cento dos neurônios durante cada passo de treinamento. Este mecanismo de regularização reduz co-adaptação entre neurônios e melhora capacidade de generalização a dados desvistos.

A segunda camada oculta recebe como entrada as duzentos e cinquenta e seis ativações da primeira camada e produz cento e vinte e oito dimensões através de operação linear análoga. Novamente, aplica-se ReLU, BatchNormalization e Dropout de trinta por cento, mantendo a consistência arquitetural e regularização. A terceira camada oculta reduz dimensionalidade de cento e vinte e oito para sessenta e quatro, com ReLU e Dropout de vinte por cento (reduzido porque mais próximo à saída final), mas sem BatchNormalization neste ponto uma vez que o modelo já convergiu significativamente. Finalmente, a camada de saída transforma as sessenta e quatro ativações da última camada oculta em um único valor escalar através de transformação linear, seguido pela função sigmoide $\sigma(z) = 1/(1 + e^{-z})$, que comprime o valor em intervalo $[0, 1]$, permitindo interpretação como probabilidade posterior de autenticidade.

O número total de parâmetros treináveis nesta arquitetura é aproximadamente quarenta e quatro mil trezentos e trinta e sete, compartilhado entre pesos das transformações lineares (quarenta e um mil quatrocentos e noventa e oito) e parâmetros de escala e deslocamento nas camadas de normalização de lote (dois mil oitocentos e trinta e nove). Esta magnitude de rede é suficiente para capturar fronteiras de decisão sofisticadas enquanto permanece computacionalmente eficiente, permitindo inferência em menos de dez milissegundos por amostra.

2) *3.2 Configuração de Treinamento e Hiperparâmetros:* O treinamento é executado utilizando o otimizador Adam (Adaptive Moment Estimation) com taxa de aprendizado inicial de 0,001. O otimizador Adam mantém estimativas adaptativas de primeiro e segundo momentos dos gradientes para cada parâmetro, resultando em taxas de aprendizado individualizadas que aceleram convergência em dimensões com gradientes pequenos enquanto se mantém cauteloso em dimensões com gradientes grandes. O treinamento processa minilotes de duzentos e cinquenta e seis amostras por iteração.

A função de perda utilizada é entropia cruzada binária com ponderação de classes, expressa como $L = -y \log(\hat{y}) - (1 - y) \log(1 - \hat{y})$, onde y é o rótulo verdadeiro (zero ou um) e $\hat{y}$ é a probabilidade predita pela rede. A ponderação de classes é computada dinamicamente para equilibrar qualquer desequilíbrio de classe residual após amostragem estratificada, embora o conjunto de dados já tenha sido equilibrado no estágio de geração.

O treinamento executa para no máximo cem épocas, compreendendo aproximadamente catorze mil itens de otimização total (trezentos e sessenta mil amostras de treinamento divididas por tamanho de lote de duzentos e cinquenta e seis). No entanto, mecanismos de regularização adiantada interrompem o processo se não houver melhoria sustentada em métricas de validação. Especificamente, parada antecipada monitora a perda de validação ao final de cada época e interrompe treinamento se nenhuma melhoria for observada em quinze épocas consecutivas, preservando pesos da época com menor perda de validação. Complementarmente, um agendador de taxa de aprendizado reduz a taxa de aprendizado por fator de zero vírgula cinco sempre que a perda de validação platô por cinco épocas consecutivas, com limite mínimo de taxa de aprendizado em um vezes dez elevado a menos seis. Esta combinação de callbacks de treinamento garante convergência sem overfitting, aproveitando plenamente o tempo computacional disponível enquanto evita memorização de características específicas do conjunto de treinamento.

3) 3.3 *Processo de Treinamento e Métricas de Convergência*: Durante o treinamento, a rede é exposta a sequências de minilotes amostrados aleatoriamente do conjunto de treinamento. Para cada minilote, a rede comuta para modo de treinamento, onde dropout está ativo e BatchNormalization utiliza estatísticas de minilote. O passe direto comuta o minilote através de todas as camadas sequencialmente, acumulando transformações lineares, ativações não-lineares e regularizações. A perda é computada comparando probabilidades de saída com rótulos verdadeiros. O passe reverso propaga gradientes da perda de volta através de todas as camadas, computando derivadas parciais da perda em relação a cada parâmetro. O otimizador Adam atualiza todos os parâmetros proporcionalmente a estes gradientes, ajustado por estimativas adaptativas de momento. Após cada época (passar por todas as amostras de treinamento), o modelo é comutado para modo de avaliação onde dropout está desativo e BatchNormalization utiliza estatísticas populacionais agregadas do treinamento, e a perda e métricas de classificação são computadas no conjunto de validação.

As principais métricas de convergência acompanhadas durante treinamento incluem perda de treinamento e perda de validação, que devem ambas diminuir monotonicamente se convergência adequada for alcançada. Divergência entre estas duas métricas (perda de validação aumentando enquanto perda de treinamento continua diminuindo) indica overfitting. Adicionalmente, acurácia de validação (fração de predições corretas), precisão (fração de predições positivas que são corretas), sensibilidade / recordação (fração de positivos verdadeiros detectados) e taxa de falso positivo são acompanhadas para fornecer perspectivas de desempenho complementárias.

O monitoramento específico da taxa de falso positivo (FPR) é crítico pois o sistema deve operar sob restrição de (probabilidade de falso alarme) menor que 10^{-7} , garantindo que atacantes fraudulentos sejam rejeitados com confiabilidade extremamente elevada. Tipicamente, o treinamento converge em cinquenta a sessenta épocas, com a parada antecipada ativando após o platô de validação.

4) 3.4 *Avaliação em Conjunto de Teste*: Após conclusão do treinamento, o modelo treinado (com pesos congelados) é avaliado em conjunto de teste completamente invisível que nunca influenciou treinamento. O conjunto de teste compreende quarenta e cinco mil amostras estratificadas mantendo proporções originais de SNR e classe. Para cada amostra de teste, o modelo comuta para modo de avaliação e executa um passe direto, produzindo probabilidade predita de autenticidade. Crítico para sistemas de autenticação em produção é a determinação de limiar de decisão apropriado que satisfaz a restrição de alfa. Enquanto classificação balanceada utiliza limiar de zero vírgula cinco, sistemas de autenticação com restrição operacional de $< 10^{-7}$ requerem deslocamento de limiar para maximizar taxa de detecção.

As métricas de desempenho computadas sobre o conjunto de teste incluem acurácia geral (fração de classificações corretas), precisão (fração de predições de autenticidade que são corretas, também conhecida como taxa de positivos verdadeiros quando restrita a predições positivas), sensibilidade ou recordação (fração de amostras autênticas detectadas corretamente, também chamada taxa de detecção), taxa de falso positivo ou FPR (fração de amostras fraudulentas incorretamente classificadas como autênticas), taxa de falso negativo (fração de amostras autênticas perdidas, falha em detectar usuários legítimos), e F1-score que balanceia precisão e recordação. Para sistemas de autenticação, a métrica crítica é a probabilidade máxima de falso alarme (sinônimo com FPR sob restrição operacional). Adicionalmente, a curva ROC (Característica Operacional de Receptor) é gerada pelo variar o limiar de decisão de zero a um e plotando taxa de detecção contra taxa de falso positivo, permitindo visualização da troca entre aceitar usuários legítimos contra rejeitar atacantes, com especial atenção na região onde $FPR < 10^{-7}$.

Nos experimentos realizados com limiar de decisão otimizado para operar sob restrição $< 10^{-7}$, o modelo alcança desempenho de autenticação robusto. Especificamente, o sistema consegue detectar usuários legítimos com probabilidade

C. 4. Teste Comparativo Figura 2 contra Método Clássico Auth-SUP

1) 4.1 *Fundamentação Teórica do Método Clássico*: O teste comparativo da Figura 2 estabelece uma comparação entre dois paradigmas para detecção de autenticidade: abordagem clássica derivada da teoria estatística de detecção de sinais versus abordagem baseada em redes neurais profundas. O método clássico implementado, referenciado como Auth-SUP (Authentication - Secure Universal Principle), foi desenvolvido por Xie, Chen e Ming em seu trabalho de 2021 sobre modelos de segurança de autenticação em camada física. Este método baseia-se no lema de Neyman-Pearson, que estabelece que

para um nível de falso alarme especificado (probabilidade de rejeitar incorretamente usuário legítimo), a regra de decisão baseada na razão de verossimilhança é estatisticamente ótima para detecção.

A formulação clássica define a regra de decisão como: rejeita-se a hipótese de autenticidade se o correlador casado τ cai abaixo de um limiar crítico τ_{limiar} , caso contrário aceita-se autenticidade. O limiar é derivado do modelo teórico assumindo ruído gaussiano, conhecimento perfeito do canal, e modelo de sinal exato. Especificamente, sob a hipótese de ruído gaussiano com variância conhecida, as distribuições do correlador sob H_0 (fraudulento) e H_1 (autêntico) são distribuições gaussianas com médias e variâncias distintas. Utilizando as estatísticas teóricas destas distribuições, o limiar é posicionado tal que a probabilidade de aceitar falsamente um atacante (falso alarme) seja exatamente igual ao nível alvo especificado, que neste experimento é estabelecido como probabilidade de falso alarme de zero vírgula um por cento.

2) 4.2 Derivação de Desempenho Teórico para Canais Rayleigh: Para canais com desvanecimento Rayleigh, o desempenho teórico do método Auth-SUP pode ser derivado através de análise matemática. A probabilidade de detecção correta (capacidade de detectar usuário autêntico quando presente) para o método clássico é expressa como:

$$P_D^{classico} = 0,5 \times \text{erfc} \left(\frac{-\sqrt{SNR_{eff}} \times L / \sqrt{L} - \sqrt{2} \times \text{erfcinv}(2 \times PFA)}{\sqrt{2}} \right)$$

onde $SNR_{eff} = SNR_{dB} \times L$ representa a razão sinal-ruído efetiva amplificada pelo ganho de processamento do comprimento TAG L (tipicamente mil e vinte e quatro símbolos), PFA é a probabilidade de falso alarme alvo (zero vírgula um por cento neste experimento), erfc é a função complementar de erro, erfcinv é o inverso da função complementar de erro, e $L = 1024$ é o comprimento típico da sequência TAG. Esta fórmula captura como a probabilidade de detecção melhora com razão sinal-ruído crescente, com a melhoria sendo proporcional à raiz quadrada do ganho de processamento do comprimento TAG.

3) 4.3 Modelo de Rede Neural para Comparação: O modelo de rede neural avaliado para comparação é o classificador treinado conforme descrito na seção anterior. Diferentemente do método clássico que utiliza apenas o correlador como estatística de teste, o modelo neural funde as quatro características engenheiradas (correlador, estimativa de canal, SNR local e energia) através de camadas densas não-lineares. A regra de decisão neural é: aceita-se autenticidade se a probabilidade posterior aprendida $P(\text{autntica}|y) > 0,5$, caso contrário rejeita-se. Esta probabilidade é computada diretamente pelo passe direto através da rede, sem referenciar limiares teóricos ou assumindo distribuições gaussianas de estatísticas.

A vantagem potencial da abordagem neural reside em sua capacidade de adaptar-se empiricamente a desvios do modelo ideal. Canais Rayleigh reais produzem distribuições de correlador que são significativamente não-gaussianas, particularmente em regimes de SNR baixo onde a distribuição é altamente assimétrica. O modelo neural, treinado em dados gerados através de simulação realista, aprende uma fronteira de decisão

que acomoda automaticamente estas não-gaussianidades. Adicionalmente, a fusão de múltiplas estatísticas pode compensar variações de canal que um correlador solitário não consegue resolver.

4) 4.4 Protocolo de Teste para Figura 2: O teste comparativo segue protocolo experimental rigoroso que garante avaliação sob restrição de falso alarme. Primeiro, o modelo neural é treinado no conjunto de treinamento de trezentos e sessenta mil amostras estratificadas uniformemente em seis faixas de SNR (zero a cinco, cinco a dez, dez a quinze, quinze a vinte, vinte a vinte e cinco, vinte e cinco a trinta decibéis). O conjunto de validação de quarenta e cinco mil amostras é utilizado para monitorar convergência durante treinamento e especialmente para monitorar taxa de falso positivo em níveis intermediários. Após convergência (tipicamente em cinquenta a sessenta épocas), o modelo é congelado e o limiar de decisão é ajustado através de análise em separado de dados de validação, determinando o limiar específico que produz $FPR = 10^{-7}$ enquanto maximiza a probabilidade de detecção.

Em segundo lugar, para cada nível de SNR de interesse no intervalo zero a trinta decibéis, um novo conjunto de teste de alto volume (tipicamente cinco mil amostras por nível de SNR) é gerado através de simulação Monte Carlo com precisão idêntica ao conjunto de treinamento. Este novo conjunto de teste garante avaliação limpa sem contaminação de dados de treinamento. Para o método clássico, o limiar de decisão é derivado a partir da restrição operacional $= 10^{-7}$, garantindo que a probabilidade de aceitar falsamente um sinal falso seja menor que 10^{-7} .

Para o método neural, as cinco mil amostras de teste em cada SNR são passadas através do modelo treinado, produzindo probabilidades preditas. Estas probabilidades são comparadas contra o limiar de zero vírgula cinco, e a fração de corretamente aceitas como autênticas é registrada como probabilidade de detecção empírica.

5) 4.5 Resultados Esperados e Características de Desempenho: Os dois métodos são então comparados graficamente. O eixo horizontal representa a razão sinal-ruído em decibéis no intervalo zero a trinta. O eixo vertical representa a probabilidade de detecção (taxa de detecção verdadeiro positivo) no intervalo zero a um. O método clássico Auth-SUP é representado como curva contínua vermelha com marcadores circulares. O método neural é representado como curva contínua azul com marcadores quadrados.

Em regimes de SNR muito baixo (zero a cinco decibéis), ambos os métodos exibem probabilidades de detecção muito pequenas, tipicamente entre cinco e oito por cento. Neste regime extremo de ruído elevado, nenhum método consegue discriminar confiavelmente entre usuários autênticos e atacantes; a tarefa é fundamentalmente próxima de conjectura aleatória. Nas regiões intermediárias de SNR (cinco a quinze decibéis), diferenças entre os métodos começam a emergir. O método neural frequentemente apresenta desempenho modestamente superior, especialmente na faixa de cinco a dez decibéis onde a sobreamostragem e aumento de dados durante treinamento forneceram dados adicionais. Nesta faixa crítica, enquanto o método clássico alcança tipicamente trinta a quarenta por cento de probabilidade de detecção, o modelo neural atinge trinta e dois a quarenta e oito por cento. Esta superioridade, embora

modesta em termos percentuais, é estatisticamente significativa e resulta de maior capacidade do modelo neural de capturar estrutura fina nas distribuições reais de correlador.

Nas regiões de SNR elevado (acima de quinze decibéis), os dois métodos convergem e praticamente coincidem. Ambos alcançam noventa e cinco a noventa e nove por cento de probabilidade de detecção na faixa de dez a vinte decibéis, e praticamente cem por cento acima de vinte decibéis. Nestes regimes elevados de SNR, ambas as abordagens (correlador clássico com limiar e fronteira neural aprendida) conseguem separar perfeitamente as duas hipóteses, tornando diferenças de método irrelevantes. A curva ROC (não apresentada graficamente mas derivável variando limiares) para o método neural é praticamente um quarto de círculo perfeito em coordenadas [eixo de taxa de falso positivo versus eixo de taxa de detecção verdadeira], refletindo desempenho praticamente ideal de classificação.

6) 4.6 Interpretação Teórica dos Resultados: Os resultados experimentais da Figura 2 fornecem validação empírica da teoria de teste de hipótese baseado em aprendizado de máquina de Braca et al. A teoria previa que classificadores de aprendizado de máquina treinados em dados realistas podem alcançar desempenho muito próximo aos limites teóricos do lema de Neyman-Pearson, enquanto sendo mais robustos a desvios de modelo. Os resultados confirmam esta predição. O método clássico atua como proxy do limite teórico assintótico, resultando em curva suave derivada matematicamente. O método neural, treinado em dados finitos, alcança desempenho comparável ao clássico e de fato superando-o ligeiramente em regiões onde desvios de gaussianidade são mais severos (SNR baixo).

A não-superioridade dramática do método neural sobre o clássico em SNR moderado reflete o fato de que o método clássico, embora derivado sob suposições gaussianas, ainda é relativamente robusto a desviações moderadas desta suposição quando a razão sinal-ruído é suficientemente elevada para permitir estimação confiável de estatísticas de amostra. Seria necessário cenários com incerteza de canal severa, interferência estruturada, ou estrutura de sinal significativamente mal-especificada para que o método neural demonstrasse superioridade mais dramática. Os experimentos atuais utilizam modelos precisamente especificados e canais bem caracterizados, minimizando vantagens relativas de adaptação do modelo neural.

7) 4.7 Anotações e Parâmetros da Figura 2: A Figura 2 inclui anotação textual especificando os parâmetros experimentais críticos. A probabilidade de falso alarme alvo é listada como zero vírgula um por cento ($PFA = 0,001$), estabelecendo implicitamente o limiar do método clássico. A modulação é especificada como BPSK (modulação por chaveamento de deslocamento de fase binária), refletindo o esquema de modulação utilizado para a mensagem. O tipo de canal é Rayleigh, confirmando que o desvanecimento é pequena-escala Rayleigh múltiplas caminhadas. O comprimento TAG é declarado como $L = 1024$ símbolos, fornecendo o ganho de processamento. O número de amostras de treinamento é especificado como 60,7k, representando a quantidade de dados únicos (antes de aumento) utilizados, com a nota que aumento de dados subsequente expandiu isto para aproximadamente

quatrocentos e cinquenta mil amostras estratificadas. Estes parâmetros contextualizados permitem reprodutibilidade completa do experimento por pesquisadores independentes.

D. 5. Conclusão

O procedimento metodológico descrito neste trabalho demonstra uma abordagem sistemática e rigorosa para aplicação de redes neurais profundas ao problema de autenticação em camada física. A geração de dados de treinamento através de amostragem estratificada com aumento sintético em regiões críticas garante que o modelo neural aprenda representações robustas e generalizáveis. O treinamento através de otimização estocástica com callbacks de regularização adiantada e agendamento adaptativo de taxa de aprendizado assegura convergência estável. A validação comparativa contra métodos clássicos fornece contexto quantitativo para o desempenho alcançado, posicionando a abordagem neural dentro do cenário estabelecido de teoria de detecção de sinais. Os resultados confirmam que redes neurais profundas podem alcançar desempenho próximo aos limites teóricos ótimos enquanto mantendo robustez a desvios de modelo e interpretabilidade em aplicações de teste de hipótese.

E. Geração dos dados de treinamento da DNN

Para o treinamento, foram escolhidas 4 features com características fundamentais para o aprendizado da rede

A pipeline de treinamento segue o seguinte fluxo: é gerado um par de treinamento (features, label)

IV. ANÁLISE DE RESULTADOS

V. CONCLUSÕES E PRÓXIMOS PASSOS

VI. FIGURAS E TABELAS

A Tabela I é apenas um exemplo [2].

TABELA I
O caption VEM ANTES DA TABELA.

	title page	odd page	even page
onesided	leftTEXT	leftTEXT	leftTEXT
twosided	leftTEXT	rightTEXT	leftTEXT

A Figura 1 é apenas um exemplo [2].




Fig. 1. Esta figura é apenas um exemplo. O caption deve vir após a figura.

VII. EQUAÇÕES

Este é um exemplo de como incluir uma equação no texto.

$$h(t) = \sum_{n=0}^{N-1} \alpha_n \delta(t - \tau_n), \quad (1)$$

onde α_n é o n -ésimo...

Observe que (1) é apenas um exemplo. Existem diferentes formas de incluir equações com múltiplas linhas, como

$$\begin{aligned} x^2 &= bx + c \\ y^2 &= \beta y + \gamma = 0. \end{aligned} \quad (2)$$

Eq. (2) é apenas um exemplo.

VIII. CONCLUSÕES

A versão final do artigo aceito para publicação nos Anais do XLIV Simpósio Brasileiro de Telecomunicações e Processamento de Sinais deve ser enviada, em formato PDF, no máximo até o dia especificado na chamada de trabalhos. O formato do artigo deve ser A4, coluna-dupla, 10pt, lado-único, e possuir no máximo 5 páginas. O Resumo e o *Abstract* devem ter no máximo 100 palavras cada um.

AGRADECIMENTOS

A Coordenação Técnica do SBrT 2026 agradece as coordenações dos simpósios anteriores promovidos pela Sociedade Brasileira de Telecomunicações por disponibilizarem este exemplo.

REFERÊNCIAS

- [1] L. Lamport, *A Document Preparation System: $\text{\LaTeX}$, User's Guide and Reference Manual*. Addison Wesley Publishing Company, 1986.
- [2] F. C. Silva e J. J. Sousa, "Esta referência é apenas um exemplo," *Revista de Exemplos*, v. 5, pp. 52–55, Maio 1999.

APÊNDICE

Inserir as informações referentes aos apêndices aqui.